Ekstrakcija značajki slike

Prof. dr. sc. Sven Lončarić
http://www.fer.hr/predmet/obrinf

Uvod

- engl. image feature extraction
- U velikom broju aplikacija potrebno je odrediti značajke slike na osnovu kojih se računalom može opisati, interpretirati ili razumjeti sadržaj slike
- Ekstrakcija značajki predstavlja početnu kariku u lancu analize slike
- Ekstrakcija značajki igra važnu ulogu u metodama za segmentaciju i klasifikaciju sadržaja slike

Pregled tema

- Prostorne značajke (spatial features)
- Detekcija rubova (edge detection)

Sustav za računalni vid

- engl. computer vision system

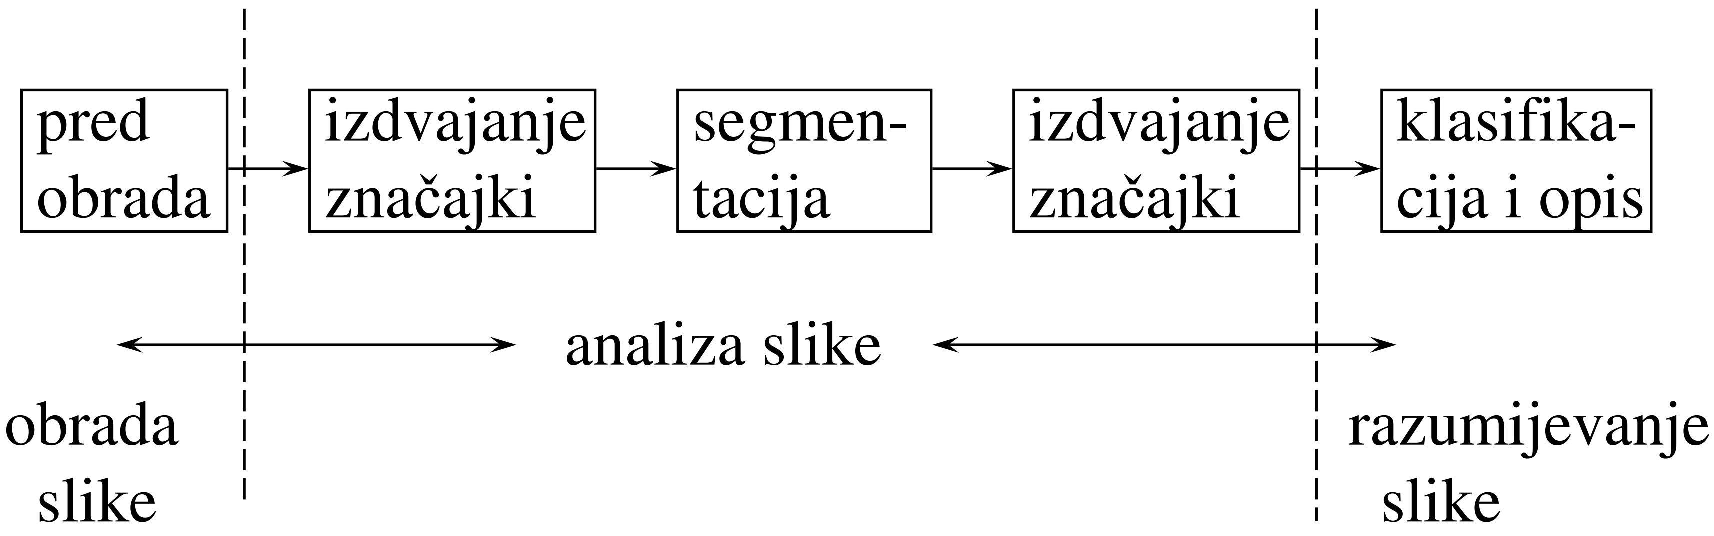

Prostorne značajke

- Ova vrsta značajki se direktno izvodi iz vrijednosti elemenata slike
- Postoje dve grupe prostornih značajki:
  - amplitudne značajke
  - značajke histograma

Amplitudne značajke

- Srednja vrijednost u nekoj točki izračunata u okolini dimenzija $W \times W$:

$$M(j,k) = \frac{1}{W^2} \sum_{m=-w}^{w} \sum_{n=-w}^{w} x(j+m, k+n)$$

  gdje je $W = 2w+1$, a $x(m,n)$ ulazna slika
- Standardna devijacija u okolini $W \times W$:

$$S(j,k) = \frac{1}{W^2} \sum_{m=-w}^{w} \sum_{n=-w}^{w} \left[x(j+m, k+n) - M(j+m, k+n) \right]^2$$

Histogram prvog reda

- Neka je u slučajna varijabla koja predstavlja vrijednosti točaka slike
- Definirajmo funkciju gustoće vjerojatnosti:

$$p_u(x) = P[u = x] \cong \frac{N_x}{N}, \quad 0 \le x \le L-1$$

gdje je N_x broj točaka u slici s vrijednošću x, a N je ukupan broj točaka u slici

- Kvocjent N_x / N predstavlja ocjenu funkcije $p_u(x)$ i naziva se histogram prvog reda

Značajke histograma I

- Momenti:

$$m_i = E\left[u^i\right] = \sum_{x=0}^{L-1} x^i p_u(x), \quad i = 1,2,\ldots$$

- Apsolutni momenti:

$$m_i' = E\left[|u|^i\right] = \sum_{x=0}^{L-1} |x|^i p_u(x)$$

- Centralni momenti:

$$\mu_i = E\left[(u - E(u))^i\right] = \sum_{x=0}^{L-1} (x - m_1)^i p_u(x)$$

Značajke histograma II

- Apsolutni centralni momenti:

$$\mu_i' = E\left[\left|u - E(u)\right|^i\right] = \sum_{x=0}^{L-1} \left|x - m_1\right|^i p_u(x)$$

- Entropija:

$$H = E\left[-\log_2 p_u\right] = -\sum_{x=0}^{L-1} p_u(x) \log_2 p_u(x)$$

Značajke histograma III

- Često se koriste slijedeće značajke:
  - disperzija: μ_1'
  - srednja vrijednost: m_1
  - varijanca: μ_2
  - prosječna energija: m_2
  - engl. skewness: μ_3
  - engl. kurtosis: μ_4 - 3
- Histogram se može računati globalno ili lokalno (unutar pomičnog prozora nekih dimenzija)

Detekcija rubova I

- Detekcija rubova je važna u analizi slika zato što rubovi određuju granice objekata i zato su korisni za segmentaciju registraciju i identifikaciju objekata na slici
- Rubovi su mjesta naglih promjena u vrijednosti točaka slike
- Zato je moguće koristiti gradijent funkcije za detekciju ruba

Detekcija rubova II

- Gradijent funkcije dviju varijabli je vektor koji pokazuje smjer najbrže promjene funkcije *f*

$$\text{grad } f(x,y) = \begin{bmatrix} \dfrac{\partial f(x,y)}{\partial x} & \dfrac{\partial f(x,y)}{\partial y} \end{bmatrix}^T = \begin{bmatrix} f_x & f_y \end{bmatrix}^T$$

- Neka je **u** jedinični vektor orijentiran u smjeru ϑ :

$$\mathbf{u} = \begin{bmatrix} \cos\theta & \sin\theta \end{bmatrix}^T$$

Detekcija rubova III

- Duljina komponente vektora gradijenta u smjeru vektora u dana je skalarnim produktom:

$$\langle \mathbf{u}, \mathrm{grad}\, f \rangle = f_x \cos\theta + f_y \sin\theta$$

- Odabirom kuta ϑ moguće je mjeriti brzinu promjene funkcije u željenom smjeru (detektirati rubove raznih orijentacija)

Detekcija rubova IV

- S obzirom na detekciju smjera ruba postoji podjela na gradijentne (u dva ortogonalna smjera) i kompas (u više smjerova) operatore
- Za diskretne slike operatori se često nazivaju i maske
- Rezultat konvolucije slike s maskama predstavlja ocjenu ortogonalnih gradijenata f_x, f_y

Gradijentni operatori I

- Gradijentni operator je definiran s dvije maske koje mjere gradijent slike $u(m,n)$ u dva ortogonalna smjera
- Neka su maske $h_1(m,n)$, $h_2(m,n)$
- Tada je rezultat konvolucije slike s maskama:

$$g_1(m,n) = \sum_i \sum_j h_1(i,j)u(m-i,n-j)$$
$$g_2(m,n) = \sum_i \sum_j h_2(i,j)u(m-i,n-j)$$

Gradijentni operatori II

- Iznos i smjer gradijentnog vektora mogu se izračunati na slijedeći način:

$$g(m,n) = \sqrt{g_1^2(m,n) + g_2^2(m,n)}$$

$$\theta_g(m,n) = \tan^{-1}\frac{g_2(m,n)}{g_1(m,n)}$$

Gradijentni operatori III

- Detekcija ruba gradijentnim operatorom prikazana je na slici

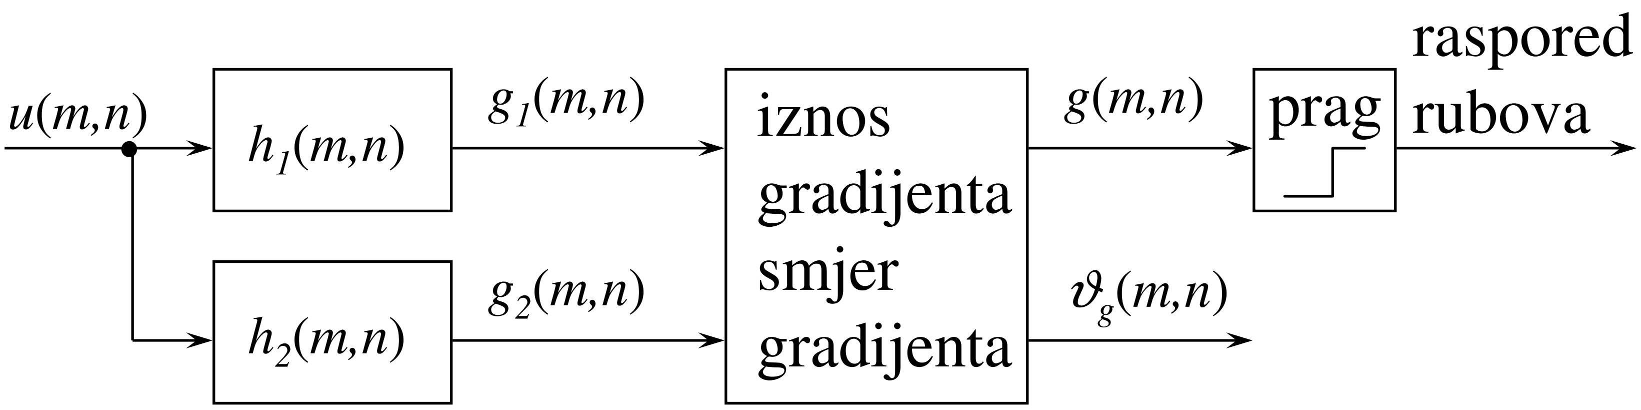

Primjeri gradijentnih operatora I

	$h_1(m,n)$	$h_2(m,n)$
Roberts	$\begin{matrix} 0 & 1 \\ -1 & 0 \end{matrix}$	$\begin{matrix} 1 & 0 \\ 0 & -1 \end{matrix}$
Prewitt	$\begin{matrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{matrix}$	$\begin{matrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{matrix}$

Primjeri gradijentnih operatora II

	$h_1(m,n)$	$h_2(m,n)$
Sobel	$\begin{matrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{matrix}$	$\begin{matrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{matrix}$
Frei-Chen	$\begin{matrix} -1 & 0 & 1 \\ -\sqrt{2} & 0 & \sqrt{2} \\ -1 & 0 & 1 \end{matrix}$	$\begin{matrix} -1 & -\sqrt{2} & -1 \\ 0 & 0 & 0 \\ 1 & \sqrt{2} & 1 \end{matrix}$

Ograničenja gradijentnih operatora

- Problem: Nemogućnost točne detekcije ruba u prisutnosti smetnji (šuma)
- Rješenje: Povećanje dimenzija maski da bi se postigao efekt usrednjavanja radi smanjenja utjecaja šuma

Prewitt horizontalna maska 7x7

$$H = \frac{1}{21}\begin{bmatrix} 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \end{bmatrix}$$

Primjer gradijenata

Original image Prewitt 7x7 pyramid 9x9

DroG 11x11 Argyle 11x11 Macleod 11x11

Laplace-ov operator I

- Gradijentne maske daju najbolje rezultate za oštre rubove (nagla promjena vrijednosti točaka)
- Kada rubovi postaju blaži (širi prijelaz) bolje rezultate daju druge derivacije
- Često se koristi Laplace-ov operator:

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

Laplace-ov operator II

- Kontinuirani Laplace-ov operator u diskretnom slučaju nadomješta se maskom
- Konvolucija maske s slikom daje ocjenu (engl. estimate) Laplace-ovog operatora
- Tablica prikazuje tri diskretna operatora za ocjenu vrijednosti Laplaceovog operatora:

$$\begin{matrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{matrix} \qquad \begin{matrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{matrix} \qquad \begin{matrix} 1 & -2 & 1 \\ -2 & 4 & -2 \\ 1 & -2 & 1 \end{matrix}$$

Laplace-ov operator III

- Upotrebom Lapace operatora moguće je izračunati položaj rubova na dva načina:
  1. odziv bloka prag na funkciju $\nabla^2 f$
  2. nule funkcije $\nabla^2 f$
- Prvi način ne daje dobre rezultate zato jer proizvodi dvostruke rubove
- Drugi način je bolji ali postoji velika osjetljivost na šum (zbog druge derivacije)

Detekcija prolazom kroz nulu

- Slika desno ilustrira detekciju rubova prolazom druge derivacije kroz nulu (jednodimenzionalni slučaj)
- engl. zero-crossing edge detection

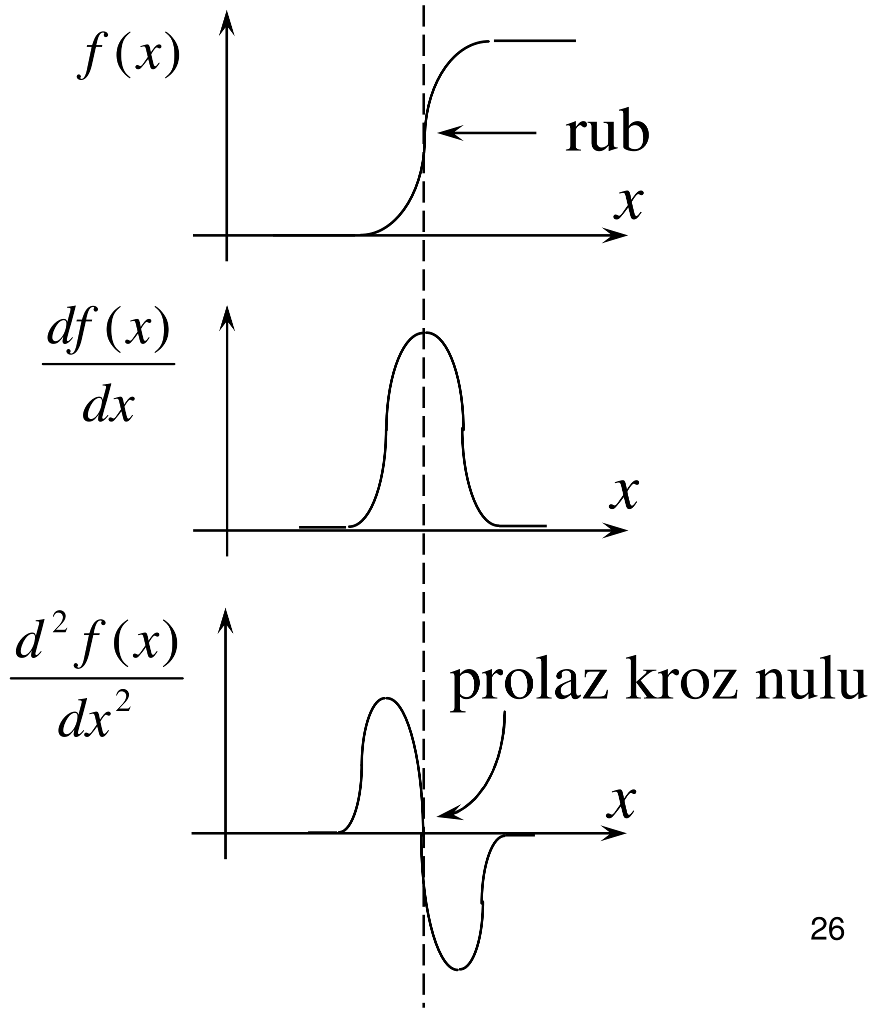

Generalizirani Laplace operator

- Zbog osjetljivosti na šum $\nabla^2 f$ operatoru Marr je dodao NP filter Gaussovog oblika tako da je frekvencijska karakteristika kobinacije jednaka:

$$H(\xi_1, \xi_2) = (\xi_1^2 + \xi_2^2)\exp\left[-2\sigma^2(\xi_1^2 + \xi_2^2)\right]$$

$$h(m,n) = c(1 - \frac{m^2 + n^2}{\sigma^2})\exp(-\frac{m^2 + n^2}{2\sigma^2})$$

- Položaj rubova je određen nulama odziva na gornji filter (engl. zero-crossings)

Primjer detekcije rubova prolazom kroz nulu

Detekcija granica

- Granica objekta je skup povezanih rubova koji predstavljaju oblik objekta
- Granica je korisna za opis i određivanje geometrijskih značajki (površina ili orijentacija)
- Granica se može odrediti postupkom povezivanja rubova (engl. edge linking)

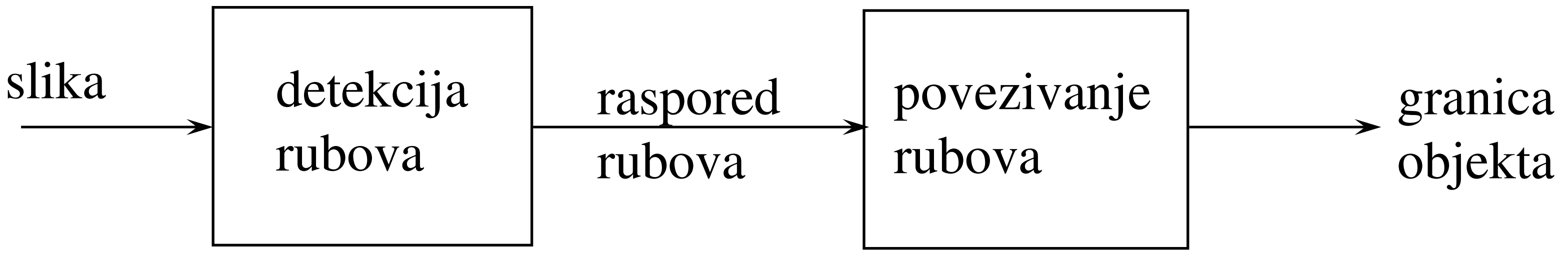

Praćenje konture I

- Kod binarnih slika granica objekta može se naći postupkom praćenja konture (engl. contour following, bug following)

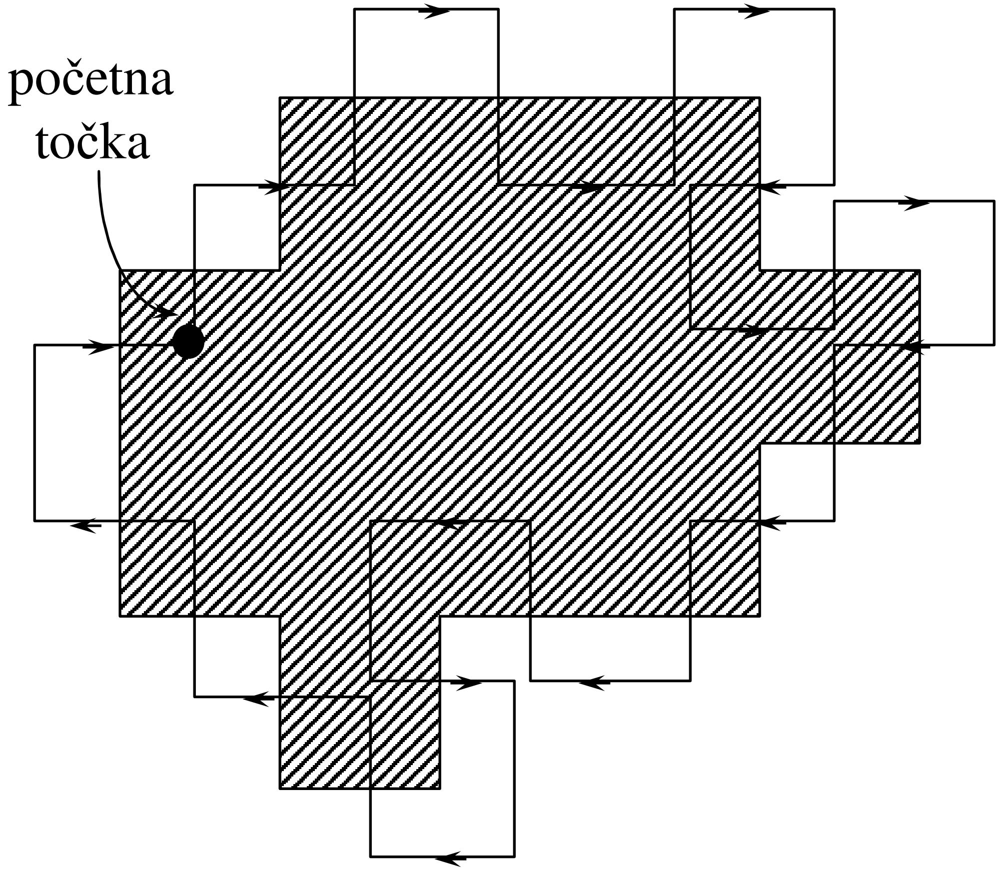

Praćenje konture II

Algoritam: Praćenje konture

1. Odaberi početnu točku unutar objekta uz granicu
2. Napravi početni korak preko granice objekta
3. Dok se ne stigne u početnu točku ponavljaj
4. Ako je trenutna pozicija unutar objekta
   - onda napravi korak u lijevo
   - inače napravi korak u desno

Zaključak

- Značajke slike važne su za više nivoe u hijerarhiji analize slike: segmentaciju, prepoznavanje, ...
- Predstavljene su osnovne metode za ekstrakciju značajki slike:
  - Prostorne značajke
  - Detekcija rubova